



Dipartimento di Economia Statistica e Finanza

Corso di Laurea in Data Science per le Strategie Aziendali

AI Econometrics Lab Panel 2

Professoressa

Camilla Mastromarco

Studente

Pierfrancesco Lindia

256641

Anno Accademico 2025 / 2026

Indice

1	Introduzione	1
2	Descrizione del dataset e analisi descrittiva preliminare	1
2.1	Prompt utilizzato per la generazione dello script R	4
3	Problema econometrico nei modelli panel dinamici	6
4	Modelli benchmark: pooled OLS e fixed effects dinamico	7
4.1	Prompt utilizzato per la stima dei modelli benchmark	8
5	Stima Arellano–Bond	9
5.1	Diagnostica del modello	10
5.2	Prompt utilizzato per la stima Arellano–Bond	10
6	Strategia alternativa sugli strumenti	11
6.1	Prompt utilizzato per l’analisi di robustezza sugli strumenti	12
7	Classificazione dei regressori e specificazione alternativa	13
7.1	Prompt utilizzato per la specificazione con <code>lfeed</code> predeterminata . . .	14
8	Risposte alle domande dell’esercitazione	14
8.1	Questioni concettuali	14
8.2	Test diagnostici e validità degli strumenti	15
8.3	Interpretazione empirica	15
8.4	Valutazione critica del ruolo del test $AR(2)$	16
9	Conclusioni	16

1 Introduzione

L'obiettivo dell'analisi è stimare un modello panel dinamico per la produzione di latte, utilizzando dati relativi ad aziende agricole osservate nel tempo. La variabile dipendente è la produzione di latte, espressa in logaritmo come `lmilk`, mentre le principali variabili esplicative sono gli input produttivi `lcows`, `lland` e `lfeed`, corrispondenti rispettivamente al logaritmo del numero di vacche, della terra disponibile e dell'alimentazione.

Il punto centrale dell'analisi riguarda la possibile persistenza della produzione. In un contesto agricolo, aziende con livelli elevati di produzione in un dato anno possono mantenere livelli elevati anche negli anni successivi, per effetto della qualità della mandria, delle capacità manageriali, della dotazione produttiva, delle strategie alimentari e di altre caratteristiche persistenti.

Il modello dinamico di riferimento può essere scritto come:

$$\log(MILK_{it}) = \phi \log(MILK_{i,t-1}) + \beta_1 \log(COWS_{it}) + \beta_2 \log(LAND_{it}) + \beta_3 \log(FEED_{it}) + \alpha_i + u_{it} \quad (1)$$

dove i identifica l'azienda agricola, t l'anno, α_i rappresenta l'effetto individuale non osservato e costante nel tempo, mentre u_{it} è il termine di errore idiosincratico. Il coefficiente ϕ misura la persistenza della produzione: se positivo e inferiore a uno, indica che la produzione passata influenza positivamente quella corrente, senza generare una dinamica esplosiva.

La presenza della variabile dipendente ritardata rende problematico l'utilizzo di stimatori standard come pooled OLS e fixed effects. Infatti, la produzione ritardata è correlata con l'effetto individuale non osservato e, anche dopo la trasformazione within, permane un problema di endogeneità dinamica. Per questo motivo, l'analisi utilizza lo stimatore Arellano–Bond in differenze, che elimina gli effetti individuali tramite differenziazione e impiega ritardi della variabile dipendente come strumenti interni.

Nel processo di analisi empirica è previsto anche il supporto di strumenti di intelligenza artificiale, utilizzati principalmente per assistere la scrittura, l'organizzazione e il debugging del codice in R.

2 Descrizione del dataset e analisi descrittiva preliminare

Il dataset utilizzato contiene informazioni relative a 247 aziende agricole osservate annualmente nel periodo 1993–1998. La struttura panel è definita dalla variabile **FARM**, che identifica l'azienda agricola, e dalla variabile **YEAR**, che identifica la dimensione temporale. Il dataset contiene complessivamente 1482 osservazioni e risulta bilanciato, poiché ciascuna azienda è osservata per tutti i 6 anni del periodo considerato.

Tabella 1: Struttura del panel

Caratteristica	Valore
Numero di aziende agricole	247
Periodo osservato	1993–1998
Numero di anni	6
Numero di osservazioni	1482
Tipo di panel	Bilanciato
Valori mancanti	Assenti

Le variabili originarie disponibili nel dataset sono **MILK**, **COWS**, **LAND**, **LABOR** e **FEED**. In coerenza con la specificazione del modello dinamico, l’analisi si concentra sulla produzione di latte e su tre input produttivi principali: numero di vacche, terra disponibile e alimentazione. Le variabili utilizzate nella stima sono ottenute attraverso trasformazione logaritmica:

$$lmilk_{it} = \log(MILK_{it}) \quad (2)$$

$$lcows_{it} = \log(COWS_{it}) \quad (3)$$

$$lland_{it} = \log(LAND_{it}) \quad (4)$$

$$lfeed_{it} = \log(FEED_{it}) \quad (5)$$


L’uso dei logaritmi consente di interpretare i coefficienti delle variabili esplicative come elasticità di breve periodo, ossia come variazioni percentuali approssimate della produzione di latte associate a variazioni percentuali degli input produttivi, condizionatamente alla specificazione dinamica.

Tabella 2: Statistiche descrittive delle variabili logaritmiche

Variabile	Media	Dev. std.	Min	Max
lmilk	11.577	0.643	9.576	13.497
lcows	2.979	0.489	1.504	4.410
lland	2.461	0.456	0.693	3.809
lfeed	10.685	0.760	8.275	12.839

Le statistiche descrittive mostrano una significativa eterogeneità tra le aziende agricole. La variabile **lmilk** presenta una media pari a 11.577 e una deviazione standard pari a 0.643, con valori compresi tra 9.576 e 13.497. Anche gli input produttivi mostrano una variabilità rilevante: in particolare, **lfeed** presenta la deviazione standard più elevata tra le variabili esplicative considerate, suggerendo differenze consistenti nell’intensità di utilizzo dell’alimentazione tra aziende.

Il boxplot della produzione logaritmica di latte per azienda evidenzia una marcata eterogeneità cross-section. Alcune aziende presentano livelli di produzione stabilmente più elevati, mentre altre si collocano su livelli sensibilmente inferiori. Questa evidenza suggerisce la presenza di caratteristiche aziendali persistenti, come dimensione produttiva, qualità manageriale, dotazione di capitale, qualità della mandria o condizioni strutturali, che possono influenzare sistematicamente la produzione.




L'andamento medio della produzione di latte nel tempo mostra una crescita regolare nel periodo osservato. La media di `lmilk` passa da 11.371 nel 1993 a 11.748 nel 1998, segnalando un aumento progressivo della produzione media tra le aziende agricole del campione.

Tabella 3: Produzione media logaritmica di latte per anno

Anno	Media di <code>lmilk</code>
1993	11.371
1994	11.471
1995	11.553
1996	11.635
1997	11.686
1998	11.748

Come mostrato in Figura ??, la produzione media logaritmica di latte aumenta in modo pressoché continuo tra il 1993 e il 1998. Questa dinamica può riflettere miglioramenti produttivi, maggiore utilizzo degli input o cambiamenti tecnologici comuni alle aziende agricole nel periodo osservato.

Il grafico relativo ad alcune aziende selezionate mostra traiettorie produttive generalmente persistenti. Le aziende con livelli iniziali più elevati di `lmilk` tendono a mantenere livelli elevati anche negli anni successivi, mentre le aziende con livelli più bassi rimangono su traiettorie inferiori. Questa evidenza descrittiva è coerente con l'ipotesi di persistenza nella produzione di latte e motiva l'utilizzo di un modello panel dinamico.



Nel complesso, l'analisi preliminare evidenzia tre aspetti rilevanti. In primo luogo, il dataset presenta una struttura panel bilanciata, con 247 aziende osservate per 6 anni. In secondo luogo, emerge una significativa eterogeneità tra aziende agricole. In terzo luogo, la dinamica temporale della produzione suggerisce una possibile persistenza del processo produttivo. Questi elementi giustificano l'utilizzo di modelli panel dinamici.

2.1 Prompt utilizzato per la generazione dello script R

Nel processo di predisposizione dello script R relativo all'analisi descrittiva iniziale del dataset panel, è stato utilizzato il seguente prompt come supporto alla generazione del codice di riferimento:


Agisci come un esperto di econometria applicata con R.

Devo creare uno script R per l'analisi descrittiva iniziale di un dataset panel.

Il dataset si chiama "farms1.txt" ed è separato da tabulazioni. Contiene dati su aziende agricole osservate dal 1993 al 1998. Le variabili principali sono:

- FARM: identificativo dell'azienda agricola
- YEAR: anno
- MILK: produzione di latte
- COWS: numero di vacche
- LAND: terra disponibile
- FEED: alimentazione

Distribution of log milk production across farms



- LABOR: lavoro

Genera uno script R ordinato e commentato che:

1. Importi il dataset.
2. Controlli struttura, nomi delle variabili, dimensioni e valori mancanti.
3. Crei le variabili logaritmiche `lmilk`, `lcows`, `lland` e `lfeed`.
4. Dichiaro il dataset come panel usando `FARM` e `YEAR`.
5. Verifichi se il panel bilanciato.
6. Calcoli statistiche descrittive per le variabili logaritmiche.
7. Calcoli l'andamento medio di `lmilk` per anno.
8. Produca un grafico dell'andamento medio di `lmilk` nel tempo.
9. Produca un grafico di `lmilk` nel tempo per alcune aziende selezionate.
10. Produca un boxplot di `lmilk` per azienda.

Usa il pacchetto `plm` e funzioni base di R.

Inserisci commenti in italiano nel codice.

Non stimare modelli econometrici: il codice deve limitarsi alla descrizione del dataset e all'analisi descrittiva preliminare.

3 Problema econometrico nei modelli panel dinamici

L'evidenza descrittiva ha mostrato una certa persistenza nella produzione di latte: le aziende con livelli produttivi elevati tendono a mantenere livelli relativamente elevati anche negli anni successivi. Per modellare esplicitamente questa dinamica è necessario includere tra i regressori la variabile dipendente ritardata.

La specificazione dinamica di riferimento è:

$$lmilk_{it} = \phi lmilk_{i,t-1} + \beta_1 lcows_{it} + \beta_2 lland_{it} + \beta_3 lfeed_{it} + \alpha_i + u_{it} \quad (6)$$

dove $lmilk_{it}$ rappresenta il logaritmo della produzione di latte dell'azienda i nell'anno t , mentre $lmilk_{i,t-1}$ rappresenta la produzione ritardata. Il coefficiente ϕ misura il grado di persistenza della produzione. Un valore positivo di ϕ indica che il livello passato di produzione contribuisce a spiegare il livello corrente.

La presenza della variabile dipendente ritardata genera tuttavia un problema econometrico rilevante. Nel modello pooled OLS, l'effetto individuale non osservato α_i è incluso nel termine di errore composito. Poiché $lmilk_{i,t-1}$ dipende anche dall'effetto specifico dell'azienda, la variabile ritardata risulta correlata con l'errore. Di conseguenza, lo stimatore pooled OLS non è consistente.

Anche il modello a effetti fissi, pur eliminando l'eterogeneità individuale non osservata costante nel tempo, presenta un problema nei panel dinamici. La trasformazione within sottrae a ciascuna variabile la propria media individuale, ma la variabile dipendente ritardata trasformata rimane correlata con l'errore trasformato. Questo genera una distorsione nota come *Nickell bias*, particolarmente rilevante quando la dimensione temporale T è piccola.

Nel dataset analizzato, la dimensione temporale è pari a 6 anni. Pertanto, il problema del bias dinamico non può essere trascurato. I modelli pooled OLS e fixed effects possono essere utilizzati come benchmark, ma non rappresentano stimatori pienamente affidabili per il modello dinamico.

Una possibile soluzione consiste nel trasformare il modello in differenze prime:

$$\Delta lmilk_{it} = \phi \Delta lmilk_{i,t-1} + \beta_1 \Delta lcows_{it} + \beta_2 \Delta lland_{it} + \beta_3 \Delta lfeed_{it} + \Delta u_{it} \quad (7)$$

La differenziazione elimina l'effetto individuale α_i , ma non risolve completamente il problema di endogeneità. Infatti, $\Delta lmilk_{i,t-1}$ rimane correlata con Δu_{it} . Per questo motivo è necessario utilizzare strumenti validi per la variabile dipendente ritardata in differenze.

Lo stimatore Arellano–Bond affronta questo problema utilizzando ritardi più profondi della variabile dipendente in livelli come strumenti interni. Sotto l'ipotesi di assenza di autocorrelazione seriale di secondo ordine negli errori, i valori ritardati di $lmilk$ possono essere utilizzati come strumenti per la variabile dipendente ritardata differenziata.

4 Modelli benchmark: pooled OLS e fixed effects dinamico

Prima di stimare il modello dinamico mediante Arellano–Bond, vengono considerate due specificazioni benchmark: il pooled OLS dinamico e il modello a effetti fissi dinamico. Questi modelli non rappresentano la specificazione finale dell’analisi, poiché entrambi presentano problemi di consistenza in presenza della variabile dipendente ritardata. Tuttavia, essi sono utili per fornire un primo confronto empirico sulla persistenza della produzione di latte.

La specificazione stimata è:

$$lmilk_{it} = \phi lmilk_{i,t-1} + \beta_1 lcows_{it} + \beta_2lland_{it} + \beta_3 lfeed_{it} + \alpha_i + u_{it} \quad (8)$$

Nel modello pooled OLS l’effetto individuale α_i non viene esplicitamente controllato, mentre nel modello a effetti fissi esso viene eliminato tramite trasformazione within.

Tabella 4: Modelli benchmark dinamici		
Variabile	Pooled OLS	Fixed Effects
lag(lmilk,1)	0.5196*** (0.0377)	0.1446*** (0.0220)
lcows	0.2875*** (0.0372)	0.5826*** (0.0354)
lland	0.0138 (0.0144)	0.0360** (0.0173)
lfeed	0.2400*** (0.0207)	0.2987*** (0.0208)
Osservazioni	1235	1235
Aziende	247	247
Anni utilizzati	5	5

Nota: errori standard robusti clusterizzati per azienda tra parentesi.

Significatività: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Nel modello pooled OLS, il coefficiente della variabile dipendente ritardata è pari a 0.5196 ed è statisticamente significativo. Questo risultato suggerisce una rilevante persistenza della produzione di latte. Tuttavia, questa stima può essere distorta verso l’alto, poiché il modello pooled OLS non controlla per caratteristiche aziendali non osservate e persistenti.

Nel modello a effetti fissi, il coefficiente di `lag(lmilk,1)` si riduce sensibilmente, passando a 0.1446, pur rimanendo statisticamente significativo. Questa riduzione è coerente con il fatto che il modello a effetti fissi elimina la componente individuale non osservata. Tuttavia, in un panel dinamico con una dimensione temporale pari a soli 6 anni, lo stimatore fixed effects è soggetto a distorsione dinamica, nota come *Nickell bias*.

Le variabili `lcows` e `lfeed` risultano positive e statisticamente significative in entrambe le specificazioni. Questo risultato è coerente con la teoria della produzione agricola: un maggiore numero di vacche e un maggiore utilizzo di alimentazione sono

associati a una maggiore produzione di latte. La variabile `lland` non risulta significativa nel pooled OLS, mentre diventa positiva e significativa nel modello a effetti fissi.

4.1 Prompt utilizzato per la stima dei modelli benchmark

Nel processo di predisposizione dello script R relativo alla stima dei modelli benchmark, è stato utilizzato il seguente prompt come supporto alla generazione del codice di riferimento:

Agisci come un esperto di econometria per dati panel e programmazione in R.

Devo creare uno script R per stimare due modelli benchmark in un contesto di panel dinamico: un modello pooled OLS dinamico e un modello fixed effects dinamico.

Il dataset si chiama "farms1.txt" ed è separato da tabulazioni. Il dataset contiene informazioni su aziende agricole osservate nel tempo. Le variabili principali sono:

- FARM: identificativo dell'azienda agricola
- YEAR: anno
- MILK: produzione di latte
- COWS: numero di vacche
- LAND: terra disponibile
- FEED: alimentazione
- LABOR: lavoro

Lo script deve:

1. Pulire il workspace.
2. Impostare la working directory:
C:/Users/lindi/Desktop/Econometria/Esercitazione 2
3. Caricare i pacchetti necessari `plm` e `lmtest`.
4. Importare il dataset `farms1.txt`.
5. Ordinare il dataset per FARM e YEAR.
6. Creare le variabili logaritmiche `lmilk`, `lcows`, `lland` e `lfeed`.
7. Dichiarare la struttura panel usando FARM e YEAR.
8. Stimare un modello pooled OLS dinamico.
9. Stimare un modello fixed effects dinamico.
10. Calcolare errori standard robusti clusterizzati per azienda.
11. Creare una tabella di confronto dei coefficienti.
12. Riportare il numero di osservazioni utilizzate.

Inserisci commenti chiari in italiano nel codice.

Evidenzia che pooled OLS e fixed effects sono modelli benchmark e non specificazioni definitive, perché nei modelli panel dinamici la presenza della variabile dipendente ritardata genera problemi di endogeneità e bias dinamico.

5 Stima Arellano–Bond

Dopo aver stimato i modelli benchmark, l’analisi procede con lo stimatore Arellano–Bond in differenze. Questo approccio è adatto ai modelli panel dinamici con molte unità cross-section e pochi periodi temporali, come nel caso del dataset considerato, composto da 247 aziende agricole osservate per 6 anni.

Applicando la trasformazione in differenze prime si ottiene:

$$\Delta l\text{milk}_{it} = \phi \Delta l\text{milk}_{i,t-1} + \beta_1 \Delta l\text{cows}_{it} + \beta_2 \Delta l\text{land}_{it} + \beta_3 \Delta l\text{feed}_{it} + \Delta u_{it} \quad (9)$$

La differenziazione elimina l’effetto individuale non osservato α_i , ma la variabile $\Delta l\text{milk}_{i,t-1}$ rimane correlata con il termine di errore differenziato Δu_{it} . Per questo motivo, lo stimatore Arellano–Bond utilizza ritardi più profondi della variabile dipendente in livelli come strumenti interni. In questa specificazione, sono stati utilizzati i ritardi da 2 a 5 di `lmilk` come strumenti.

Sono state stimate due versioni del modello: una specificazione one-step e una specificazione two-step. I risultati principali sono riportati nella Tabella 5.

Tabella 5: Stima Arellano–Bond: one-step e two-step

Variable	AB one-step	AB two-step
<code>lag(lmilk,1)</code>	0.3000*** (0.0333)	0.2919*** (0.0328)
<code>lcows</code>	0.5798*** (0.0377)	0.5735*** (0.0376)
<code>lland</code>	0.0548*** (0.0202)	0.0412** (0.0200)
<code>lfeed</code>	0.2229*** (0.0227)	0.2371*** (0.0235)
Osservazioni	988	988
Aziende	247	247

Nota: stime Difference GMM; errori standard robusti tra parentesi.

Significatività: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Il coefficiente della variabile dipendente ritardata è positivo e statisticamente significativo in entrambe le specificazioni. Nel modello one-step è pari a 0.3000, mentre nel modello two-step è pari a 0.2919. Questo risultato conferma la presenza di persistenza nella produzione di latte: un livello più elevato di produzione nell’anno precedente è associato a un livello più elevato di produzione nell’anno corrente. Poiché il coefficiente è inferiore a uno, la dinamica stimata non suggerisce un processo esplosivo.

Anche le variabili relative agli input produttivi risultano positive e statisticamente significative. Il coefficiente di `lcows` è pari a 0.5798 nel modello one-step e 0.5735 nel modello two-step, indicando che il numero di vacche è fortemente associato alla produzione di latte. La variabile `lfeed` presenta un coefficiente pari a 0.2229 nel modello one-step e 0.2371 nel modello two-step, confermando il ruolo positivo dell’alimentazione nel processo produttivo. Anche `lland` risulta positiva e significativa, sebbene con un coefficiente più contenuto.

5.1 Diagnostica del modello

La validità dello stimatore Arellano–Bond dipende in modo cruciale dalla validità degli strumenti e dall'assenza di autocorrelazione seriale di secondo ordine negli errori differenziati. Per questo motivo sono stati considerati i test AR(1), AR(2) e il test di Sargan sulle restrizioni di sovraidentificazione.

Tabella 6: Test diagnostici Arellano–Bond

Test	AB one-step	AB two-step
AR(1) p-value	< 0.001	< 0.001
AR(2) p-value	0.6755	0.7065
Sargan p-value	0.1123	0.1429

Il test AR(1) risulta significativo in entrambe le specificazioni. Questo risultato è atteso nei modelli stimati in differenze prime, poiché la differenziazione induce generalmente autocorrelazione di primo ordine anche quando gli errori in livelli non sono serialmente correlati.

Il test AR(2), invece, è il test più rilevante per valutare la validità degli strumenti. In entrambe le specificazioni il p-value è elevato: 0.6755 nel modello one-step e 0.7065 nel modello two-step. Di conseguenza, non si rifiuta l'ipotesi nulla di assenza di autocorrelazione di secondo ordine. Questo risultato supporta la validità dell'utilizzo dei ritardi della variabile dipendente come strumenti.

Infine, il test di Sargan non rifiuta la validità complessiva delle restrizioni di sovraidentificazione. Il p-value è pari a 0.1123 nel modello one-step e 0.1429 nel modello two-step. Questi risultati indicano che non emerge evidenza statistica contro la validità complessiva degli strumenti utilizzati.

5.2 Prompt utilizzato per la stima Arellano–Bond

Nel processo di predisposizione dello script R relativo alla stima Arellano–Bond, è stato utilizzato il seguente prompt come supporto alla generazione del codice di riferimento:

```
Agisci come un esperto di econometria per dati panel dinamici e
programmazione in R.
```

```
Devo creare uno script R per stimare un modello panel dinamico con lo
stimatore Arellano-Bond Difference GMM.
```

```
Il dataset si chiama "farms1.txt" ed è separato da tabulazioni. Il dataset
contiene informazioni su aziende agricole osservate nel tempo.
```

```
Lo script deve:
```

1. Pulire il workspace.
2. Impostare la working directory:
C:/Users/lindi/Desktop/Econometria/Esercitazione 2
3. Caricare i pacchetti necessari plm e lmtest.
4. Importare il dataset.
5. Ordinare il dataset per FARM e YEAR.
6. Creare le variabili logaritmiche lmlk, lcows, lland e lfeed.

7. Dichiarare la struttura panel usando FARM e YEAR.
8. Stimare un modello Arellano-Bond Difference GMM one-step.
9. Stimare un modello Arellano-Bond Difference GMM two-step.
10. Trattare `lag(lmilk,1)` come variabile dinamica endogena.
11. Utilizzare `lag(lmilk, 2:5)` come strumenti interni.
12. Confrontare i coefficienti one-step e two-step.
13. Eseguire i test AR(1), AR(2) e Sargan.
14. Stampare gli output principali da conservare per la relazione.

Usa la funzione `pgmm()` del pacchetto `plm`.

Inserisci commenti chiari in italiano nel codice.

6 Strategia alternativa sugli strumenti

Una questione rilevante nei modelli GMM per dati panel dinamici riguarda il numero di strumenti utilizzati. L'impiego di un numero eccessivo di strumenti può generare problemi di *instrument proliferation*, rendendo i test di sovraidentificazione meno informativi e aumentando il rischio di sovradattamento delle variabili endogene. Per questo motivo, oltre alla specificazione baseline con strumenti basati sui ritardi `lag(lmilk, 2:5)`, viene stimata una specificazione più parsimoniosa che utilizza solo `lag(lmilk, 2:3)`.

Tabella 7: Confronto tra specificazioni Arellano-Bond con diverso set di strumenti

Variabile	AB lag 2:5	AB lag 2:3
<code>lag(lmilk,1)</code>	0.2919*** (0.0328)	0.2920*** (0.0335)
<code>lcows</code>	0.5735*** (0.0376)	0.5718*** (0.0400)
<code>lland</code>	0.0412** (0.0200)	0.0405* (0.0212)
<code>lfeed</code>	0.2371*** (0.0235)	0.2350*** (0.0230)
Osservazioni	988	988
Aziende	247	247

Nota: stime Arellano-Bond two-step in differenze prime.

Significatività: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Il confronto tra le due specificazioni mostra una notevole stabilità dei coefficienti stimati. Il coefficiente della variabile dipendente ritardata è pari a 0.2919 nella specificazione baseline e a 0.2920 nella specificazione con strumenti ridotti. Questo risultato indica che la stima della persistenza della produzione di latte non dipende in modo sostanziale dall'utilizzo dei ritardi più profondi come strumenti.

Anche i coefficienti degli input produttivi risultano molto simili. Il coefficiente di `lcows` passa da 0.5735 a 0.5718, mentre quello di `lfeed` passa da 0.2371 a 0.2350. La variabile `lland` mantiene un coefficiente positivo e di dimensione simile, anche se la significatività si riduce leggermente nella specificazione con strumenti ridotti.

Tabella 8: Diagnostica delle specificazioni con diverso set di strumenti

Modello	AR(1)	AR(2)	Sargan
AB one-step lag 2:5	< 0.001	0.6755	0.1123
AB two-step lag 2:5	< 0.001	0.7065	0.1429
AB two-step lag 2:3	< 0.001	0.6985	0.0672

La diagnostica conferma la validità generale delle specificazioni. Il test AR(1) risulta significativo in tutti i casi, come atteso nei modelli stimati in differenze prime. Il test AR(2), invece, non è significativo in nessuna specificazione. Questo risultato è particolarmente importante, poiché l'assenza di autocorrelazione seriale di secondo ordine supporta la validità degli strumenti basati sui ritardi della variabile dipendente.

Il test di Sargan non rifiuta la validità complessiva degli strumenti nella specificazione baseline. Nella specificazione con strumenti ridotti, il p-value si riduce a 0.0672, restando comunque superiore al livello del 5%. Nel complesso, la riduzione del set di strumenti non modifica in modo sostanziale i risultati principali.

6.1 Prompt utilizzato per l'analisi di robustezza sugli strumenti

Nel processo di predisposizione dello script R relativo all'analisi di robustezza sul set di strumenti, è stato utilizzato il seguente prompt come supporto alla generazione del codice di riferimento:

Agisci come un esperto di econometria per dati panel dinamici e programmazione in R.

Devo creare uno script R per verificare la robustezza di un modello Arellano-Bond rispetto alla scelta del set di strumenti.

Il dataset si chiama "farms1.txt" ed è separato da tabulazioni.

Lo script deve:

1. Importare il dataset.
2. Creare le variabili logaritmiche `lmilk`, `lcows`, `lland` e `lfeed`.
3. Dichiarare la struttura panel con `FARM` e `YEAR`.
4. Stimare una specificazione Arellano-Bond two-step baseline usando `lag(lmilk, 2:5)` come strumenti.
5. Stimare una specificazione più parsimoniosa usando `lag(lmilk, 2:3)` come strumenti.
6. Confrontare i coefficienti dei due modelli.
7. Eseguire per entrambi i modelli i test AR(1), AR(2) e Sargan.
8. Creare una tabella riassuntiva con i p-value diagnostici.

Usa la funzione `pgmm()` del pacchetto `plm`.

Inserisci commenti chiari in italiano nel codice, spiegando che la riduzione del set di strumenti serve a valutare la robustezza delle stime e a limitare il rischio di instrument proliferation.

7 Classificazione dei regressori e specificazione alternativa

La specificazione Arellano–Bond stimata inizialmente tratta `lcows`, `lland` e `lfeed` come regressori strettamente esogeni. Tuttavia, dal punto di vista economico, questa ipotesi può essere discussa.

La variabile `lland` può essere considerata relativamente esogena o predeterminata, poiché la dotazione di terra tende a variare lentamente nel tempo e non risponde immediatamente agli shock produttivi annuali. La variabile `lcows` può essere interpretata come predeterminata, poiché il numero di vacche riflette decisioni produttive prese in precedenza e può dipendere dalla storia produttiva dell’azienda. La variabile `lfeed`, invece, è potenzialmente predeterminata: le decisioni sull’alimentazione possono essere influenzate dalle aspettative produttive o da shock osservati dall’agricoltore, ma non necessariamente dagli shock idiosincratici contemporanei non osservati.

Per questo motivo, viene stimata una specificazione alternativa in cui `lfeed` è trattata come predeterminata, utilizzando i ritardi `lag(lfeed, 2:3)` come strumenti aggiuntivi.

Tabella 9: Specificazione alternativa con `lfeed` predeterminata

Variabile	Baseline lag 2:3	<code>lfeed</code> predeterminata
<code>lag(lmilk, 1)</code>	0.2920*** (0.0335)	0.2970*** (0.0646)
<code>lcows</code>	0.5718*** (0.0400)	0.5732*** (0.0741)
<code>lland</code>	0.0405* (0.0212)	0.0377 (0.0234)
<code>lfeed</code>	0.2350*** (0.0230)	0.2354*** (0.0824)
Osservazioni	988	988
Aziende	247	247

Nota: stime Arellano–Bond two-step in differenze prime.

Significatività: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

I risultati mostrano che la specificazione alternativa produce coefficienti molto simili alla baseline. Il coefficiente della variabile dipendente ritardata passa da 0.2920 a 0.2970, rimanendo positivo e statisticamente significativo. Anche il coefficiente di `lcows` rimane sostanzialmente invariato. Il coefficiente di `lfeed` resta positivo e significativo, con valore pari a 0.2354. Questo conferma il ruolo rilevante dell’alimentazione nella produzione di latte.

Tabella 10: Diagnostica della specificazione con `lfeed` predeterminata

Modello	AR(1)	AR(2)	Sargan
Baseline lag 2:3	< 0.001	0.6985	0.0672
<code>lfeed</code> predeterminata	< 0.001	0.7073	0.1626

La diagnostica è favorevole. Il test AR(2) non è significativo nella specificazione con `lfeed` predeterminata, con p-value pari a 0.7073. Inoltre, il test di Sargan presenta un

p-value pari a 0.1626, superiore a quello della baseline con strumenti ridotti. Questo suggerisce che la specificazione alternativa non presenta evidenza contro la validità degli strumenti.

Nel complesso, trattare `lfeed` come predeterminata non modifica in modo sostanziale i risultati principali. La persistenza della produzione rimane stabile, il ruolo di `lcows` e `lfeed` resta positivo e significativo, e la diagnostica del modello risulta coerente con la validità della specificazione.

7.1 Prompt utilizzato per la specificazione con `lfeed` predeterminata

Nel processo di predisposizione dello script R relativo alla specificazione alternativa con `lfeed` predeterminata, è stato utilizzato il seguente prompt come supporto alla generazione del codice di riferimento:

```
Agisci come un esperto di econometria per dati panel dinamici e
programmazione in R.
```

```
Devo creare uno script R per stimare una specificazione alternativa Arellano
-Bond in cui la variabile lfeed viene trattata come predeterminata.
```

```
Il dataset si chiama "farms1.txt" ed è separato da tabulazioni.
```

```
Lo script deve:
```

1. Importare il dataset.
2. Creare le variabili logaritmiche `lmilk`, `lcows`, `lland` e `lfeed`.
3. Dichiarare la struttura panel usando `FARM` e `YEAR`.
4. Stimare una specificazione baseline Arellano-Bond two-step con strumenti `lag(lmilk, 2:3)`.
5. Stimare una specificazione alternativa aggiungendo `lag(lfeed, 2:3)` come strumenti.
6. Confrontare i coefficienti della baseline e della specificazione alternativa.
7. Eseguire i test `AR(1)`, `AR(2)` e Sargan per entrambe le specificazioni.
8. Creare una tabella diagnostica con i p-value dei test.

```
Usa la funzione pgmm() del pacchetto plm.
```

```
Inserisci commenti chiari in italiano nel codice, spiegando che la
specificazione alternativa serve a valutare se i risultati sono robusti
quando FEED viene trattata come variabile predeterminata.
```

8 Risposte alle domande dell'esercitazione

8.1 Questioni concettuali

Il pooled OLS è inconsistente perché la variabile dipendente ritardata, `lag(lmilk, 1)`, è correlata con l'effetto individuale non osservato α_i . Poiché il pooled OLS non con-

trolla tale effetto, esso entra nel termine di errore composito e genera correlazione tra regressore ed errore.

Anche lo stimatore fixed effects non è pienamente appropriato in un panel dinamico con T piccolo. La trasformazione within elimina α_i , ma la variabile dipendente ritardata trasformata rimane correlata con l'errore trasformato. Questo genera il cosiddetto *Nickell bias*. Nel nostro caso, la stima fixed effects del coefficiente di persistenza è pari a 0.1446, molto inferiore alla stima Arellano–Bond pari a circa 0.292. Questo pattern è coerente con una distorsione verso il basso dello stimatore fixed effects.

La differenziazione prima elimina l'effetto individuale α_i , ma non risolve da sola il problema di endogeneità. Infatti, $\Delta \text{lmilk}_{i,t-1}$ contiene $u_{i,t-1}$ ed è quindi correlata con $\Delta u_{it} = u_{it} - u_{i,t-1}$. Per questo motivo servono strumenti validi.

Il ritardo $\text{lmilk}_{i,t-2}$ può essere utilizzato come strumento per $\Delta \text{lmilk}_{i,t-1}$ sotto l'ipotesi di assenza di autocorrelazione seriale negli errori idiosincratici. Al contrario, $\text{lmilk}_{i,t-1}$ non è valido, perché è direttamente collegato alla componente $u_{i,t-1}$ contenuta nell'errore differenziato.

Nel metodo Arellano–Bond, il set di strumenti cresce nel tempo perché, man mano che si osservano periodi successivi, diventano disponibili più ritardi validi della variabile dipendente.

8.2 Test diagnostici e validità degli strumenti

Nel modello in differenze prime, la presenza di autocorrelazione AR(1) nei residui è attesa, anche se gli errori in livelli non sono serialmente correlati. Questo accade perché Δu_{it} e $\Delta u_{i,t-1}$ condividono il termine $u_{i,t-1}$.

Il test AR(2) è invece cruciale. Se fosse significativo, indicherebbe autocorrelazione di secondo ordine negli errori differenziati e metterebbe in discussione la validità degli strumenti basati sui ritardi. Nel nostro caso, il test AR(2) non è significativo nelle specificazioni principali: il p-value è pari a 0.7065 nel modello Arellano–Bond two-step con strumenti `lag(lmilk,2:5)` e pari a 0.6985 nella specificazione con strumenti ridotti. Questo supporta la validità delle condizioni di momento.

Il test di Sargan valuta la validità complessiva delle restrizioni di sovraidentificazione. Nella specificazione Arellano–Bond two-step baseline il p-value è pari a 0.1429, quindi non si rifiuta l'ipotesi nulla di validità degli strumenti. Nella specificazione con strumenti ridotti il p-value scende a 0.0672, rimanendo comunque superiore al 5%. Nella specificazione con `lfeed` predeterminata il p-value aumenta a 0.1626.

L'uso di molti strumenti può aumentare l'efficienza, ma può anche generare *instrument proliferation*. Questo può rendere i test di sovraidentificazione deboli o poco informativi e può portare il modello a sovradattare le variabili endogene. Per questo motivo è utile confrontare la specificazione con strumenti `lag(lmilk,2:5)` con quella più parsimoniosa `lag(lmilk,2:3)`.

8.3 Interpretazione empirica

Il coefficiente stimato della variabile dipendente ritardata nel modello Arellano–Bond two-step è pari a 0.2919. Questo valore indica una persistenza positiva della produzione di latte, ma non particolarmente elevata. Poiché il coefficiente è inferiore a uno, la dinamica non è esplosiva: uno shock alla produzione tende a propagarsi nel tempo, ma con intensità decrescente.

La short-run elasticity rispetto a `lfeed` è pari a circa 0.2371 nella specificazione Arellano–Bond two-step baseline. Ciò significa che, a parità degli altri fattori e condizionatamente alla dinamica del modello, un aumento dell'1% dell'alimentazione è associato a un aumento approssimativo dello 0.237% della produzione di latte nel breve periodo.

Il confronto tra pooled OLS, fixed effects e Arellano–Bond mostra differenze economicamente rilevanti. Il pooled OLS stima un coefficiente di persistenza pari a 0.5196, probabilmente distorto verso l'alto perché non controlla l'eterogeneità aziendale non osservata. Il fixed effects stima un coefficiente pari a 0.1446, plausibilmente distorto verso il basso a causa del Nickell bias. Arellano–Bond fornisce una stima intermedia, pari a circa 0.292, ed è quindi più coerente con la teoria econometrica dei panel dinamici.

La specificazione preferita per l'interpretazione sostanziale è il modello Arellano–Bond two-step con `lfeed` trattata come predeterminata. Questa scelta è motivata da tre elementi: i coefficienti sono stabili rispetto alla baseline, il test AR(2) non è significativo, e il test di Sargan non rifiuta la validità degli strumenti con un p-value pari a 0.1626. Inoltre, dal punto di vista economico, è plausibile che le decisioni sull'alimentazione siano influenzate da condizioni produttive passate o aspettative, e quindi siano meglio rappresentate come predeterminate piuttosto che strettamente esogene.

8.4 Valutazione critica del ruolo del test AR(2)

Il test AR(2) è fondamentale nel framework Arellano–Bond perché verifica se esiste autocorrelazione seriale di secondo ordine nei residui differenziati. Se AR(2) fosse significativo, i ritardi utilizzati come strumenti potrebbero essere correlati con l'errore differenziato, invalidando le condizioni di momento alla base dello stimatore.

Nel nostro caso, la spiegazione teorica del test AR(2) è coerente con i risultati empirici: i p-value sono elevati nelle principali specificazioni, quindi non emerge evidenza di autocorrelazione di secondo ordine. Questo supporta la validità degli strumenti utilizzati e rafforza l'affidabilità della stima Arellano–Bond.

9 Conclusioni

L'analisi ha stimato un modello panel dinamico per la produzione di latte utilizzando un dataset bilanciato composto da 247 aziende agricole osservate annualmente nel periodo 1993–1998. L'obiettivo principale era valutare la persistenza della produzione e stimare le elasticità di breve periodo rispetto agli input produttivi principali: numero di vacche, terra disponibile e alimentazione.

L'analisi descrittiva ha mostrato una crescita regolare della produzione media logaritmica di latte nel tempo e una marcata eterogeneità tra aziende. Questi elementi hanno motivato l'utilizzo di un modello panel dinamico con effetti individuali non osservati.

I modelli benchmark pooled OLS e fixed effects forniscono risultati diversi sul coefficiente della variabile dipendente ritardata. Il pooled OLS stima una persistenza pari a 0.5196, mentre il fixed effects produce una stima pari a 0.1446. Questa differenza è coerente con i problemi teorici degli stimatori standard nei panel dinamici: il pooled

OLS non controlla l'eterogeneità individuale non osservata, mentre il fixed effects è soggetto a Nickell bias quando la dimensione temporale è ridotta.

La stima Arellano–Bond consente di affrontare il problema dell'endogeneità dinamica utilizzando ritardi della variabile dipendente come strumenti interni. I risultati mostrano una persistenza positiva della produzione di latte, con un coefficiente di circa 0.292 nella specificazione two-step. Gli input produttivi risultano positivamente associati alla produzione, in particolare il numero di vacche e l'alimentazione.

I test diagnostici supportano la validità generale della specificazione: AR(1) è significativo, come atteso nei modelli in differenze prime, mentre AR(2) non è significativo. Il test di Sargan non rifiuta la validità complessiva degli strumenti nelle specificazioni principali. Inoltre, la riduzione del set di strumenti da `lag(lmilk,2:5)` a `lag(lmilk,2:3)` non modifica sostanzialmente i coefficienti stimati, suggerendo robustezza rispetto al problema della proliferazione degli strumenti.

Infine, la specificazione alternativa in cui `lfeed` è trattata come predeterminata conferma la stabilità dei risultati e presenta una diagnostica favorevole. Per questo motivo, tale specificazione può essere considerata la più convincente per l'interpretazione sostanziale, poiché combina plausibilità economica, stabilità dei coefficienti e validità diagnostica.

Codice R e materiali del progetto: https://github.com/PierfrancescoLindia/AI_Econometrics_Lab_Panel_2/tree/main